

UNIVERSIDAD DE LA SABANA

Facultad de Ingeniería

ML No Supervisado — Semestre 2026-II



Proyecto Retador

Patrones Invisibles: Información, Incertidumbre y Movilidad Urbana

Dataset:	NYC Taxi Trip Duration — Kaggle
Modalidad:	Grupal (4 integrantes, roles diferenciados)
Cargue de archivos:	Domingo 27 de septiembre de 2026, 11:00 p.m.
Defensa oral:	Lunes 28 de septiembre de 2026, en el horario de clase
Duración del video:	10 a 12 minutos (grupal)
Duración de la defensa:	3 minutos por integrante
Valor:	5.0 (escala institucional 0.0–5.0)

Prof. Eduardo Carrillo B.

Jefatura de Inteligencia Artificial — Universidad de La Sabana

Bogotá, Colombia — 2026-II

Índice

1	El Escenario Profesional	2
1.1	Planteamiento	2
1.2	El valor diferencial del equipo consultor	2
1.3	Por qué trabajo en equipo con roles diferenciados	2
1.4	Resumen ejecutivo de los entregables	3
2	El Dataset: NYC Taxi Trip Duration	3
2.1	Acceso y características generales	3
2.2	Variables principales	3
2.3	Variables derivadas sugeridas	4
3	La Misión: Roles del Equipo	4
3.1	Libertad analítica con responsabilidad metodológica	4
3.2	Los 4 roles	4
3.2.1	Rol 1 — Analista de Incertidumbre e Información	4
3.2.2	Rol 2 — Arquitecto de Segmentación por Partición	4
3.2.3	Rol 3 — Modelador de Mezclas y Variables Latentes	5
3.2.4	Rol 4 — Estratega de Negocio y Selección de Datos	5
3.3	Uso de Inteligencia Artificial	5
4	El Entregable: Video Grupal de 10-12 Minutos	5
4.1	Naturaleza del entregable	5
4.2	Estructura del video	6
4.3	Cómo grabar el video	6
4.4	Documento de soporte en PDF	7
5	La Defensa Oral	7
5.1	Formato y dinámica	7
6	Rúbrica de Evaluación	7
6.1	Cómo se calcula la nota total del grupo	7
6.2	Rúbrica detallada por bloque técnico	8
6.3	Penalizaciones automáticas	8

1 El Escenario Profesional

1.1 Planteamiento

El presente proyecto sitúa al equipo en el rol de **consultoría analítica** contratada por **UrbanMove**, una plataforma de movilidad que opera flotas de vehículos en Nueva York y compite directamente por la asignación eficiente de conductores en tiempo y espacio. La dirección de operaciones de UrbanMove ha entregado al equipo consultor un histórico de viajes reales de taxi en la ciudad, con la siguiente instrucción:

“Tenemos más de un millón de viajes históricos y no sabemos qué hacer con ellos más allá de mirar promedios. Necesitamos entender qué tan predecible es la demanda en cada zona y momento del día, qué perfiles de viaje existen realmente (no los que nosotros imaginamos), y dónde debemos posicionar conductores para minimizar tiempos de espera sin sobre-ofertar en zonas de baja demanda. Todo hallazgo debe estar cuantificado — no queremos opiniones, queremos números defendibles.”

— Dirección de Operaciones, UrbanMove

1.2 El valor diferencial del equipo consultor

Ejecutar mecánicamente un algoritmo de clustering sobre coordenadas geográficas es una competencia técnica necesaria pero insuficiente. UrbanMove no necesita un mapa de colores; necesita saber **cuánta incertidumbre real hay en la demanda, qué tan distintos son los patrones entre momentos del día, y qué decisión operativa concreta** se deriva de cada hallazgo.

Principio rector del proyecto. El dataset es el mismo para todos los equipos. Lo que diferencia un análisis sobresaliente de uno por mejorar no es la cantidad de gráficas producidas, sino la capacidad de responder: ¿cuánta información aporta realmente esta variable?, ¿qué tan seguro puedo estar de este segmento?, ¿qué debería hacer UrbanMove mañana por la mañana con este resultado?

1.3 Por qué trabajo en equipo con roles diferenciados

Este proyecto integra tres bloques teóricos de alta densidad (teoría de la información, clustering particional, y modelos de mezcla con variables latentes) que, ejecutados a profundidad por una sola persona en el tiempo disponible, sacrificarían rigor por cobertura. Por eso el equipo se conforma de **4 integrantes**, cada uno responsable técnico de un bloque, más la integración final de negocio. **Cada integrante defiende individualmente su bloque** — el trabajo grupal no diluye la responsabilidad individual de dominar el contenido propio.

1.4 Resumen ejecutivo de los entregables

Componente	Descripción	Fecha límite
Video MP4	Presentación grupal de 10-12 minutos; cada integrante presenta su bloque técnico.	Domingo 27 de sept. 11:00 p.m.
Documento PDF	Soporte escrito compartido: enlace al dataset, justificación de la selección de datos, tabla de métricas por bloque, enlace a GitHub.	Domingo 27 de sept. 11:00 p.m.
Defensa oral	3 minutos por integrante con el profesor. Preguntas sobre su bloque y al menos una pregunta de integración cruzada. Sin apuntes.	Lunes 28 de sept. en horario de clase

Advertencia metodológica

El video, el documento PDF y el enlace al repositorio GitHub deben quedar cargados a más tardar el **domingo 27 de septiembre a las 11:00 p.m.** La defensa oral se realiza al día siguiente, **lunes 28 de septiembre, en clase**. Archivos cargados después de la hora límite del domingo se consideran entrega tardía.

2 El Dataset: NYC Taxi Trip Duration

2.1 Acceso y características generales

El dataset está disponible gratuitamente en Kaggle (se requiere cuenta gratuita):

<https://www.kaggle.com/c/nyc-taxi-trip-duration/data>

Contiene aproximadamente **1.4 millones de viajes** de taxi realizados en la ciudad de Nueva York, con coordenadas de recogida y destino, marca temporal, número de pasajeros y duración del viaje. Es un dataset real, ampliamente usado en la industria y en competencias de ciencia de datos, con licencia de uso académico.

2.2 Variables principales

Variable	Descripción
<code>pickup_datetime</code>	Fecha y hora de inicio del viaje. Fuente de toda variable temporal (hora del día, día de la semana, fin de semana vs. día laboral).
<code>pickup_longitude/latitude</code>	Coordenadas geográficas de recogida. Base para segmentación espacial (zonas/hotspots).
<code>dropoff_longitude/latitude</code>	Coordenadas geográficas de destino. Permite analizar pares origen-destino.
<code>passenger_count</code>	Número de pasajeros (1 a 6 típicamente).
<code>trip_duration</code>	Duración del viaje en segundos. Variable central para perfiles de viaje.
<code>vendor_id</code>	Proveedor del servicio (2 categorías). Útil para comparaciones distribucionales.
<code>store_and_fwd_flag</code>	Indicador técnico de si el registro se almacenó localmente antes de enviarse al servidor.

Advertencia metodológica

El dataset completo supera 1.4 millones de registros. **No es necesario ni recomendable** procesar el archivo completo en cada iteración de análisis. El equipo debe justificar por escrito su estrategia de muestreo o filtrado (por ejemplo: una muestra aleatoria de 30 000–50 000 viajes, o un filtro a un mes/borough específico) — esta es una decisión metodológica evaluable, no un atajo técnico sin consecuencias.

2.3 Variables derivadas sugeridas

El equipo tiene libertad de construir variables adicionales a partir de las originales. Algunas sugerencias:

- **Distancia geodésica** (Haversine) entre recogida y destino — **no** usar distancia euclidiana directa sobre lat/lon (error conceptual grave: la Tierra no es plana).
- **Hora del día, día de la semana, fin de semana vs. laboral**, a partir de `pickup_datetime`.
- **Velocidad promedio** del viaje (distancia/duración) — útil para detectar registros anómalos.
- **Zona de recogida** (por ejemplo, mediante un grid geográfico simple o clustering preliminar) para análisis de entropía por zona.

3 La Misión: Roles del Equipo**3.1 Libertad analítica con responsabilidad metodológica**

El equipo tiene libertad para decidir *cómo* exactamente aplicar cada bloque técnico al dataset, siempre que la aplicación sea genuina (no decorativa) y esté conectada a una pregunta de negocio concreta para UrbanMove.

3.2 Los 4 roles**3.2.1 Rol 1 — Analista de Incertidumbre e Información**

Bloque temático: Probabilidad en ML, entropía de Shannon, entropía cruzada, divergencia KL, información mutua, entropía condicional, desigualdad de Jensen, log-sum-exp trick.

Aplicación esperada: cuantificar qué tan predecible (o caótica) es la demanda de viajes según zona, hora del día o día de la semana; comparar distribuciones de demanda entre dos contextos (por ejemplo, día laboral vs. fin de semana) mediante divergencia KL; medir cuánta información aporta la hora del día sobre la zona de destino mediante información mutua; usar el log-sum-exp trick al combinar probabilidades de muchas zonas sin pérdida numérica (puente directo hacia el trabajo del Rol 3).

3.2.2 Rol 2 — Arquitecto de Segmentación por Partición

Bloque temático: K-means, clustering jerárquico, DBSCAN, métricas de validación, selección de hiperparámetros.

Aplicación esperada: segmentar zonas o viajes en grupos duros usando al menos dos métodos distintos (por ejemplo K-means y DBSCAN); justificar K con método del codo y índice de silueta; justificar ϵ de DBSCAN con gráfica k -distancia; usar DBSCAN explícitamente para detectar “ruido” (viajes o zonas atípicas) y proponer un tratamiento operativo para esos casos.

3.2.3 Rol 3 — Modelador de Mezclas y Variables Latentes

Bloque temático: Modelos de mezcla gaussiana, variables latentes, algoritmo EM, convergencia e inicialización.

Aplicación esperada: modelar los viajes como una mezcla de **perfiles de movilidad latentes** (por ejemplo: commuter de hora pico, viaje nocturno largo, desplazamiento corto de fin de semana) donde cada viaje tiene una *probabilidad de pertenencia* (responsabilidad) a cada perfil, no una asignación rígida; explicar explícitamente los pasos E y M; comparar al menos dos inicializaciones (aleatoria vs. *K-means++*) y discutir sensibilidad a mínimos locales y criterio de convergencia.

3.2.4 Rol 4 — Estrategia de Negocio y Selección de Datos

Responsabilidad: justificar por escrito la selección y estructuración de datos del equipo (qué variables se usaron, qué muestreo se aplicó y por qué); integrar los hallazgos de los tres roles anteriores en **al menos tres recomendaciones operativas concretas** para UrbanMove (posicionamiento de conductores, tarificación dinámica por zona/hora, tratamiento de zonas atípicas); liderar la coherencia narrativa del documento y video finales.

Advertencia metodológica

No se aceptará un análisis que se limite a cargar el archivo, calcular estadísticas descriptivas y producir histogramas o mapas de calor sin cuantificación formal. Los ocho conceptos de teoría de la información deben aparecer aplicados con números propios (no solo mencionados), el clustering debe compararse entre al menos dos métodos con métricas de validación, y el algoritmo EM debe explicarse paso a paso con los parámetros propios del equipo — no una descripción genérica de `sklearn.mixture.GaussianMixture`.

3.3 Uso de Inteligencia Artificial

Sí se acepta el uso de herramientas de Inteligencia Artificial (ChatGPT, Claude, Copilot u otras) como apoyo durante la realización del proyecto — por ejemplo, para resolver dudas conceptuales, depurar código o mejorar la redacción. Sin embargo, **la totalidad de los análisis, interpretaciones y decisiones metodológicas presentados debe ser un producto propio de cada integrante**, no una copia de lo que una IA generó.

Advertencia metodológica

Si en el video, el documento o el código se identifica una intervención de IA **no adaptada, verificada o genuinamente comprendida por el equipo** (por ejemplo, una interpretación genérica que no corresponde a los datos propios, o código que el integrante no puede explicar en la defensa oral), se descontará **0.5 sobre la nota final del equipo por cada intervención de IA que se encuentre**. Este descuento es acumulativo y se suma a cualquier otra penalización automática de la rúbrica.

4 El Entregable: Video Grupal de 10-12 Minutos

4.1 Naturaleza del entregable

El video no es una exposición académica de definiciones. Es una presentación de resultados de consultoría: el equipo comunica qué encontró en los datos de UrbanMove, qué tan seguro está de cada hallazgo, y qué debería hacer la empresa con esa información.

Exposición académica (no se espera esto)	Presentación de consultoría (esto sí)
“La entropía de Shannon mide la incertidumbre promedio de una variable aleatoria discreta según su distribución de probabilidad...”	“La entropía de la distribución de viajes por zona en horario pico es de 3.1 bits, frente a 4.4 bits en horario valle — es decir, en hora pico la demanda está mucho más concentrada geográficamente, lo que justifica redistribuir el 20% de la flota hacia solo 4 zonas entre las 7 y 9 a.m.”

4.2 Estructura del video

Seg.	Denominación	Contenido obligatorio	Tiempo
1	Contexto y datos (Rol 4)	UrbanMove, pregunta de negocio, justificación de la muestra/filtrado de datos.	0:00–1:30
2	Incertidumbre e información (Rol 1)	Entropía por zona/horario, KL entre contextos, información mutua hora-zona, uso del log-sum-exp trick.	1:30–4:00
3	Segmentación por partición (Rol 2)	Comparación de al menos 2 métodos, justificación de hiperparámetros, métricas de validación, tratamiento del ruido.	4:00–6:30
4	Mezclas y variables latentes (Rol 3)	Perfiles de viaje como mezcla, E-step/M-step propios, comparación de inicializaciones.	6:30–9:00
5	Recomendaciones y cierre (Rol 4)	Al menos 3 recomendaciones cuantificadas para UrbanMove; limitaciones y siguientes pasos.	9:00–11:00

Duración. El video debe durar entre 10 y 12 minutos. Videos fuera de este rango reciben una penalización sobre la nota final del equipo (ver la rúbrica de evaluación).

4.3 Cómo grabar el video

El video **no requiere producción profesional**. Puede grabarse de forma sencilla con un celular. Una manera práctica de lograrlo, especialmente para la presentación de pantalla/notebooks, es crear una **reunión en Microsoft Teams** entre los integrantes del equipo y grabarla — Teams genera automáticamente el archivo de video y facilita su carga posterior.

Advertencia metodológica

Aunque la producción puede ser sencilla, **entre más fluidez y experticia demuestren los integrantes al exponer su bloque** — dominio del tema, capacidad de explicar sin leer, seguridad al responder implicaciones de negocio — **más alta será la nota**. Leer diapositivas palabra por palabra o mostrar duda evidente sobre el propio análisis afecta negativamente la calificación.

4.4 Documento de soporte en PDF

El documento se entrega junto con el video y debe contener:

- Enlace directo al dataset en Kaggle.
- Justificación escrita de la estrategia de muestreo/filtrado (máximo 200 palabras).
- Tabla de resultados por rol: valores de entropía/KL/información mutua (Rol 1); métricas de validación de clustering por método (Rol 2); parámetros finales de la mezcla gaussiana y número de iteraciones hasta convergencia (Rol 3).
- Enlace al repositorio GitHub del equipo con notebooks comentados y ejecutados.
- Nombres completos, códigos de estudiante y rol de cada integrante.

5 La Defensa Oral

5.1 Formato y dinámica

La totalidad del equipo debe participar en la defensa oral del proyecto. La defensa se realiza el **lunes 28 de septiembre de 2026, en el horario de clase**. Cada uno de los 4 integrantes sostiene una sesión individual de **3 minutos** con el profesor. El orden se determina por sorteo.

Advertencia metodológica

Durante la defensa oral **no se podrá hacer uso de equipos electrónicos ni papeles** (sin apuntes, sin código, sin el video propio, sin celular). La defensa consiste únicamente en **responder las preguntas que formule el profesor** en el momento.

Criterio de evaluación de la defensa

No se evalúa la capacidad de recitar definiciones. Se evalúa la capacidad de conectar la teoría con los números propios del equipo y de justificar cada decisión con argumentos de negocio. Una respuesta del tipo “la divergencia KL mide qué tan distintas son dos distribuciones...” sin mencionar el valor concreto obtenido para UrbanMove no es una respuesta satisfactoria. Además, **cada integrante debe poder responder al menos una pregunta sobre el bloque de un compañero** — el proyecto puntúa la comprensión del conjunto, no solo de la parte propia.

Advertencia metodológica

Las preguntas específicas de la defensa no se publican con antelación. El profesor formulará preguntas derivadas directamente del bloque temático de cada rol, aplicadas a los resultados propios del equipo.

6 Rúbrica de Evaluación

6.1 Cómo se calcula la nota total del grupo

La evaluación se realiza en la **escala oficial de la Universidad de La Sabana, de 0.0 a 5.0** (aprobación en 3.0). **Cada uno de los 4 roles se califica de forma independiente, de 0.0 a 5.0, con el mismo peso**. La nota total del grupo es el **promedio simple** de las 4 notas de rol:

$$\text{Nota del grupo} = \frac{\text{Nota Rol 1} + \text{Nota Rol 2} + \text{Nota Rol 3} + \text{Nota Rol 4}}{4}$$

Criterio	Peso	Momento
Rol 1 — Teoría de la información (individual)	25%	Video + defensa
Rol 2 — Clustering por partición (individual)	25%	Video + defensa
Rol 3 — Mezclas gaussianas y EM (individual)	25%	Video + defensa
Rol 4 — Negocio, datos e integración (individual)	25%	Video + defensa
Total (promedio de los 4 roles)	100%	

Advertencia metodológica

La calidad del video (fluidez, experticia demostrada) y la comprensión cruzada durante la defensa oral **no son criterios separados**: se reflejan directamente dentro de la nota individual de cada rol, subiendo o bajando esa nota de 0.0 a 5.0 según el desempeño observado.

6.2 Rúbrica detallada por bloque técnico

Rol	Excelente (4.5-5.0)	Bien (3.5-4.4)	Regular (3.0-3.4)	Insuf. (0.0-2.9)
Rol 1	Entropía, KL, información mutua y log-sum-exp calculados con números propios e interpretación de negocio correcta.	La mayoría de los conceptos aplicados correctamente; alguno sin interpretación de negocio.	Al menos 4 de los 6 conceptos aplicados; hay errores conceptuales.	Definiciones sin aplicación numérica real al dataset.
Rol 2	Dos métodos comparados con hiperparámetros justificados y métricas de validación completas; tratamiento explícito del ruido.	Un método bien ejecutado; el segundo con justificación incompleta.	Clustering ejecutado sin justificación rigurosa de hiperparámetros.	Un solo método sin métricas de validación.
Rol 3	E/M explícitos, convergencia documentada, comparación real de inicializaciones con interpretación.	GMM ejecutada y explicada correctamente; comparación de inicialización superficial.	GMM ejecutada con <code>sklearn</code> sin explicar E/M paso a paso.	GMM mencionado sin ejecución ni interpretación de responsabilidades.
Rol 4	Selección de datos justificada, 3+ recomendaciones cuantificadas, integra genuinamente los 3 bloques.	Recomendaciones presentes pero poco cuantificadas o integración parcial.	Recomendaciones genéricas sin conexión clara a los hallazgos técnicos.	Sin justificación de datos ni recomendaciones concretas.

6.3 Penalizaciones automáticas

Las siguientes situaciones conllevan descuento automático, independientemente de la calificación en los demás criterios (escala 0.0–5.0):

- Video fuera del rango de 10-12 minutos: descuento de **0.5** sobre la nota final del equipo.
- Ausencia del enlace al dataset o al repositorio GitHub: descuento de **0.3** por cada uno, sobre la nota final del equipo.

- Un integrante no se presenta a su defensa oral: nota de **0.0** en su rol individual, sin afectar la nota de los demás integrantes.
- Un integrante no puede responder ninguna pregunta sobre el bloque de un compañero: descuento de **0.5** sobre la nota de su propio rol.
- Análisis copiado de fuentes externas sin adaptación al dataset propio: nota de **0.0** en el rol afectado.
- Intervención de Inteligencia Artificial no adaptada, verificada o comprendida por el equipo: descuento de **0.5 sobre la nota final del equipo, por cada intervención encontrada.**